

## Unsupervised Learning & Preprocessing

Supervised learning belajar dari data yang sudah ada jawabannya, unsupervised learning kebalikannya: model cari sendiri pola dari data tanpa label. Ada dua topik besar di sini: transformasi data (scaling, PCA, NMF, t-SNE) dan clustering (K-Means, Agglomerative, DBSCAN).

### 1. Scaling: Menyamakan Skala Fitur

Algoritma berbasis jarak (SVM, K-Means, dll) sensitif kalau skala fiturnya beda jauh. Fitur bernilai besar bisa mendominasi padahal belum tentu lebih penting.

`MinMaxScaler()` -> ubah fitur ke rentang 0–1

`StandardScaler()` -> ubah fitur jadi rata-rata 0, std 1

SVM tanpa scaling akurasi jauh lebih rendah dibanding setelah di-scale.

### 2. PCA: Mengecilkan Jumlah Fitur

PCA meringkas banyak fitur jadi sedikit komponen, tapi tetap mempertahankan informasi (variansi) sebanyak mungkin.

**Contoh 1 visualisasi:** data Breast Cancer (30 fitur) diringkas jadi 2 komponen, hasilnya kelas ganas/jinak tetap terlihat terpisah di scatter plot.

**Contoh 2 ekstraksi fitur (Eigenfaces):** data wajah diringkas jadi 100 komponen (pakai `whiten=True`), akurasi KNN buat mengenali wajah jadi naik dibanding pakai piksel mentah.

### 3. NMF: Mirip PCA, Tapi Serba Positif

NMF juga menguraikan data jadi komponen, tapi semua nilainya harus non-negatif. Cocok untuk data yang memang positif secara alami, misalnya gambar, karena komponennya lebih gampang diartikan sebagai 'bagian penyusun'.

Contoh serunya: memisahkan sinyal suara yang tercampur (cocktail party problem). NMF berhasil memisahkan sinyal asli dengan baik, sedangkan PCA gagal, karena syarat non-negatif NMF lebih cocok sama sifat sinyal.

### 4. t-SNE: Jagoan Visualisasi

Khusus buat memvisualisasikan data berdimensi tinggi ke 2D. Tidak bisa dipakai ulang ke data baru (cuma ada `fit_transform()`, tanpa `transform()`). Dicoba di data digit tulisan tangan: hasil t-SNE jauh lebih rapi memisahkan tiap angka dibanding PCA.

### 5. K-Means: Clustering Paling Dasar

Membagi data ke k cluster, tiap titik masuk ke cluster dengan centroid (titik pusat) terdekat. Prosesnya diulang terus sampai penugasan clusternya stabil.

**K-Means gagal kalau:** cluster kepadatannya beda-beda, bentuknya lonjong/miring, atau bentuknya rumit (misalnya data 'two moons'), karena K-Means selalu mengasumsikan cluster berbentuk bulat.

## 6. Agglomerative Clustering & Dendrogram

Caranya bottom-up: tiap titik mulai sebagai cluster sendiri, lalu digabung terus dengan yang paling mirip sampai sisa sejumlah cluster yang diinginkan. Hasil penggabungannya bisa digambar sebagai dendrogram (diagram pohon), makin tinggi garisnya, makin beda cluster yang digabung.

## 7. DBSCAN: Berdasarkan Kepadatan

Tidak perlu menentukan jumlah cluster dari awal. Area padat = satu cluster, titik terisolasi = noise (label -1). Diatur lewat eps (radius tetangga) dan min\_samples (minimal tetangga buat jadi inti cluster).

## 8. Menilai Hasil Clustering

**ARI** dipakai kalau ada label asli, bandingkan hasil cluster dengan label sebenarnya (bukan pakai accuracy biasa, karena nama cluster bisa ketuker tapi pengelompokannya tetap benar).

**Silhouette Score** dipakai kalau tidak ada label asli, tapi cenderung condong nilai tinggi ke cluster berbentuk bulat, jadi ga selalu mencerminkan hasil yang benar-benar bagus.

## 9. Studi Kasus: Clustering Wajah

Ketiga metode (DBSCAN, K-Means, Agglomerative) dicoba di data wajah yang sudah direduksi PCA. Hasilnya: DBSCAN default cuma nemu 1 cluster besar, K-Means bikin wajah 'rata-rata' yang buram tiap cluster, dan Agglomerative lumayan masuk akal kalau jumlah clusternya diperbanyak. Kesimpulannya: clustering wajah dari piksel gambar tetap tugas yang sulit, meski sudah dibantu PCA.

### Ringkasan Cepat

**MinMax/StandardScaler** → samakan skala fitur

**PCA** → reduksi dimensi, pertahankan variansi

**NMF** → dekomposisi non-negatif, mudah diinterpretasi

**t-SNE** → visualisasi eksploratif terbaik

**K-Means** → clustering cepat, asumsi bentuk bulat

**Agglomerative** → clustering hierarkis + dendrogram

**DBSCAN** → clustering berbasis kepadatan, deteksi noise otomatis

Jadi, tidak ada satu teknik yang paling jago di semua kasus. Pilihannya tergantung bentuk data, tujuan (visualisasi/kompresi/pengelompokan), dan apakah butuh model yang bisa dipakai ulang ke data baru atau cukup sekali pakai saja.